


INSTITUTO FEDERAL DE
EDUCAÇÃO, CIÊNCIA E TECNOLOGIA
PARAÍBA
Campus João Pessoa

Introdução à Ciência de Dados

Fundamentos
Aplicações

Prof. Alex Cunha
alex@ifpb.edu.br

Dado, Informação e Conhecimento



- ▶ **Dado**: fato coletado e geralmente armazenado
- ▶ **Informação**: dado com algum **significado**
- ▶ **Conhecimento**: Informação **interpretada, descoberta, entendida** a partir de dados e **aplicada** para um fim.



Exemplo

Dados

- 1000 milibares
- 5,1 m/s; 95°
- 30 °C
- poucas
- 1000 mts

Posso tomar alguma decisão?

Informação

- Pressão atmosférica = 1000 milibares
- Velocidade e direção do vento = 5,1 m/s; 95°
- Temperatura do ar = 30 °C
- Nuvens = poucas
- Visibilidade = 1000 mts


Posso tomar alguma decisão?

Conhecimento

- A probabilidade de chuva é baixa, portanto, posso ir à praia.

Posso tomar alguma decisão?

Dados, dados, dados ...



DADOS ABERTOS

≡ kaggle

🔗 Home

🏆 Compete

📊 Data

<> Notebooks

Google

Dataset Search

Pesquisar conjuntos de dados

Testar coronavírus COVID-19 ou temperaturas globais.

Conjuntos de dados

A	B	C	D	E	F	G	H	I
Concurso,	Data Sorteio,	1ª Dezena,	2ª Dezena,	3ª Dezena,	4ª Dezena,	5ª Dezena,	6ª Dezena,	7ª Dezena,
1,11/03/1996,	4,5,30,33,41,52,0,0,	Â ,	0,17,"39158,92",	2016,"330,21",	SIM,"1714650,23",	0,0		
2,18/03/1996,	9,37,39,41,43,49,0,1,	PR ,	"2307162,23",	65,"14424,02",	4488,"208,91",	NÃO,	0,0,0	
3,25/03/1996,	10,11,29,30,36,47,0,2,	RN ,	"391192,51",	62,"10515,93",	4261,"153,01",	NÃO,	0,0,0	
SP ,								
4,01/04/1996,	1,5,6,27,42,59,0,0,	Â ,	0,39,"15322,24",	3311,"180,48",	SIM,"717080,75",	0,0		
5,08/04/1996,	1,2,6,16,19,46,0,0,	Â ,	0,98,"5318,1",	5399,"96,53",	SIM,"1342488,85",	0,0		
6,15/04/1996,	7,13,19,22,40,47,0,0,	Â ,	0,109,"7214,66",	7147,"110,03",	SIM,"2286166,33",	0,0		
7,22/04/1996,	3,5,20,21,38,56,0,0,	Â ,	0,100,"8746,05",	5736,"152,48",	SIM,"3335692,28",	0,0		
8,29/04/1996,	4,17,37,38,47,53,0,0,	Â ,	0,60,"16084,11",	5262,"183,4",	SIM,"4493748,19",	0,0		
9,06/05/1996,	8,43,54,55,56,60,0,0,	Â ,	0,17,"60043,79",	2175,"469,31",	SIM,"5718641,49",	0,0		
10,13/05/1996,	4,18,21,25,38,57,0,0,	Â ,	0,251,"6638,45",	12590,"132,35",	SIM,"13334769,81",	0,0		
11,20/05/1996,	15,25,37,38,58,59,0,1,	RJ ,	"15591365,07",	148,"12706,05",	9442,"199,16",	NÃO,	0,0,0	
12,27/05/1996,	4,16,19,20,27,43,0,0,	Â ,	0,108,"6791,17",	6454,"113,64",	SIM,"880136,24",	0,0		
13,03/06/1996,	18,32,47,50,54,56,0,0,	Â ,	0,43,"20543,98",	2934,"301,09",	SIM,"1940205,35",	0,0		
14,10/06/1996,	2,16,23,27,47,53,0,0,	Â ,	0,85,"10458,19",	5323,167,	SIM,"3006941,32",	0,0		
15,17/06/1996,	12,33,35,51,52,60,0,0,	Â ,	0,57,"17919,89",	3931,"259,84",	SIM,"4232661,35",	0,0		
16,24/06/1996,	20,32,34,49,58,60,0,0,	Â ,	0,31,"33307,13",	3250,"317,7",	SIM,"5471686,62",	0,0		
17,01/07/1996,	6,10,13,19,20,51,0,1,	SP ,	"6789869,08",	144,"7628,37",	9376,"117,16",	NÃO,	0,0,0	



Será que estamos realmente conseguindo descobrir **conhecimento útil** a partir de conjuntos de dados existentes?

Estamos ajudando na tomada de decisão com este **conhecimento**?



O que fazemos com minas de ouro???



#Analogia

É útil??

Mineração de dados (MD)

- ▶ **Abundância** de dados existentes

=> Sistematização da

preparação e **extração de**

conhecimento de grandes

bases/conjuntos de dados




A MD é a descoberta de conhecimento em função de **modelos**, padrões ou regras a partir de grandes quantidades de dados [adaptado de Navathe e Elmasri, 2010]

Como isso aconteceu?



Aprendizado de Máquina (AM)

- ▶ Subárea da inteligência artificial, do inglês “*machine learning*”, conhecida como “**aprendizado automático**”
- ▶ Objetiva prover que sistemas **aprendam um determinado comportamento** ou **padrão** automaticamente a partir de **exemplos** ou **observações**.



Aprendizado de Máquina (AM)

▶ **Aprendizado Supervisionado**

- ▶ Aprendizado em que um algoritmo aprende a mapear um **exemplo de entrada para um rótulo de saída**, utilizando como base um conjunto de exemplos históricos previamente rotulados
- ▶ **Regressão logística**: estima (prediz) a probabilidade de ocorrência de um evento **categórico** com base em um determinado conjunto de dados
- ▶ **Regressão linear**: prevê o valor de dados **contínuos** desconhecidos, usando valores de dados relacionados
- ▶ **Classificação**: tarefa que identifica a qual categoria uma observação pertence



Aprendizado de Máquina (AM)

▶ **Aprendizado Não-Supervisionado**

- ▶ “Aprendizado em que um algoritmo aprende a identificar padrões nos dados *sem supervisão humana*. Não há informações prévias sobre as saídas desejadas (dados não rotulados)”
- ▶ **Clustering**: técnica que agrupa pontos de dados (exemplos) em grupos (clusters) com base em semelhança de padrões
- ▶ **Regras de Associação**: técnica que identifica relações requentes (relacionamento) entre itens de dados em um grande dataset



Aprendizado de Máquina (AM)

▶ **Aprendizado Semi-Supervisionado**

- ▶ Aprendizado que agrega características do **aprendizado supervisionado** e **não supervisionado**.
- ▶ O conjunto de dados contém uma pequena quantidade de dados rotulados e uma **grande quantidade de dados não rotulados**
 - ▶ Aprende tanto com os exemplos que possuem “resposta” quanto com a distribuição geral dos dados.
- ▶ Mix de aplicação do aprendizado supervisionado e não supervisionado



MD x AM

- ▶ **MD:** processo de **extração automática de conhecimento** a partir de **conjuntos de dados**
- ▶ **Algoritmos de AM:**
 - ▶ Extraem um **padrão de comportamento** a partir de dados (exemplos) sem necessidade de programação explícita
 - ▶ Podem ser utilizados como algoritmos de MD
 - ▶ **Nem sempre utilizam “bases de dados”**
 - ▶ Podem aprender diretamente a partir da interação com o ambiente ou com um simulador, por exemplo.
- ▶ Ambas as áreas “importam” métodos da Estatística.



Exemplo

- ▶ Cenário: **Atribuição de crédito**

Aprendizado supervisionado

- ▶ Cliente vai ao banco solicitar financiamento para compra de carro

- ▶ *Questão 1:* O crédito será oferecido?

Classificação

- ▶ Resposta: **SIM** ou **NÃO**

- ▶ *Questão 2:* Qual o valor do crédito a ser oferecido?

- ▶ Resposta: Estimativa de R\$
5.000 reais

Regressão

Análise/mineração preditiva

Exemplo

Aprendizado Não Supervisionado

- ▶ Cenário: **E-commerce e marketing**

- ▶ Quais as tendências de compras de clientes?

- ▶ *Questão 1:* Qual o percentual de clientes que compram **X** e levam **Y**?

Regra de associação entre objetos

- ▶ Resposta:

- ▶ **Regra 1:** 90% dos clientes que compram **smartphones** assinam um **plano de dados** pro seu aparelho

X = smartphones
Y = plano de dados

Mineração/análise descritiva; aprendizado não supervisionado

Exemplo

Aprendizado Não Supervisionado

Questão 1: Como separar os clientes com base em suas cores?



3 grupos (clusters) de clientes

Mineração/análise descritiva; aprendizado não supervisionado

Exemplo

- ▶ Cenário: **Classificação de Texto e Documentos**
- ▶ Como guiar a classificação de um **grande volume de documentos** não rotulados a partir de um pequeno conjunto de textos rotulados
- ▶ *Questão 1:* Rotular manualmente textos em categorias específicas (tópicos, sentimentos) pode ser dispendioso?
- ▶ Resposta:
 - ▶ treinar um classificador inicial apenas com dados rotulados e depois utiliza-o para prever os rótulos do conjunto não rotulado

Aprendizado
Semi-
Supervisionado

As previsões mais confiáveis (limiar) são adicionadas ao conjunto de dados rotulados

Quem precisa dos modelos e análises??



Qual é o seu
problema?



Quais dados estão
disponíveis ?

Como a solução pode agregar
valor ao seu negócio/cenário?



I WANT ANSWERS



**CALL THE DATA SCIENTIST.
RIGHT NOW!**



Ciência de Dados

The logo for Data Science, featuring the words "Data" and "Science" in white text on a blue background. "Data" is on a dark blue square, and "Science" is on a light blue square.

O objetivo da **Ciência de Dados** é melhorar a tomada de decisão com base em *insights* obtidos a partir de um conjunto de dados em geral grande

Kelleher J., Tierney B., "Data Science". MIT Press, 2018.

A **Ciência de Dados** trata de estudar, usar e **analisar** o dado em todo seu **ciclo de vida** de modo a produzir **valor**


Normalmente interdisciplinar





Ciência de Dados: realidade

80% of time of data scientists spent on data pre-processing, cleansing, etc.




What data scientists spend the most time doing

- Building training sets: 3%
- Cleaning and organizing data: 60%
- Collecting data sets: 19%
- Mining data for patterns: 9%
- Refining algorithms: 4%
- Other: 5%

<https://www.forbes.com/sites/gilpress/2016/03/23/data-preparation-most-time-consuming-least-enjoyable-data-science-task-survey-says/#1905b0b76f63>



Engenharia de Dados



ETL = Extract-Transform-Load

Preparação de dados

Ciência de Dados envolve engenharia de dados!

Papéis de atuação na Ciência de Dados

▶ **Cientista de Dados**

- ▶ **Formula perguntas relevantes do negócio**, conduz a preparação dos dados, identifica padrões e insights que podem ser usados para tomar decisões estratégicas
- ▶ **Habilidades:** programação, estatística, aprendizado de máquina, análise exploratória, visualização de dados

▶ **Analista de Dados**

- ▶ Cria **relatórios** e **dashboards** para comunicar suas descobertas e ajudar as empresas a tomar decisões informadas. Também coleta e organiza dados
- ▶ **Habilidades:** SQL, Excel, ferramentas de visualização de dados (Power BI), estatística descritiva



Papéis de atuação na Ciência de Dados


▶ **Engenheiro de Dados**

- ▶ Constrói, mantém e otimiza a infraestrutura de armazenamento de dados (data warehouses, data lake) para coleta e processamento (análises)
- ▶ **Habilidades:** programação, ferramentas ETL/ELT, plataformas de cloud (AWS, Azure), conhecimento de banco de dados

▶ **Arquiteto de Dados**

- ▶ Define padrões para estrutura de coleta de dados, projeta modelos de dados, estabelece padrões e políticas de uso, garante a qualidade e acessibilidade aos dados.
- ▶ **Habilidades:** modelagem de dados, segurança de dados, governança de dados, tecnologias de dados






Ciência de dados é um termo mais comum hoje no contexto de descoberta do conhecimento


Martínez-Plumed, F., Contreras-Ochando, L., Ferri, C., Hernandez- Orallo, J., Kull, M., Lachiche, N. J. A. H., Ramírez-Quintana, M. J., & Flach, P. A. (2019). CRISP-DM Twenty Years Later: From Data Mining Processes to Data Science Trajectories. IEEE Transactions on Knowledge and Data Engineering. <https://doi.org/10.1109/TKDE.2019.2962680>

Data Science Pipeline



Algumas aplicações

Data
Science




PPGTI
Programa de Pós Graduação
em Tecnologia da Informação

IDE



Problema: Como identificar idosos internados com diagnóstico de PAC em risco de morte?

VITAL SIGNS



- Classifiers:
 - Multi-Layer Perceptron
 - Logistic Regression
 - Support Vector Machine
 - Random Forest


Predicting Mortality Risk among Elderly Inpatients with Pneumonia: A Machine Learning Approach

Victor Monteiro Silva¹, Damires Yluska de Souza Fernandes¹ and Alex Sandro da Cunha Rêgo¹

¹Federal Institute of Paraíba, João Pessoa, Brazil
monteiro.victor@academico.ifpb.edu.br, {damires,alex}@ifpb.edu.br

Keywords: Data Analysis and Prediction, CAP, Probability of Death, ROC Curve, AUC.

Abstract: Community-acquired Pneumonia (CAP) is a serious respiratory infection that can cause life-threatening risk in people of different ages, especially in elderly inpatients. Regarding this age group, mortality rates by CAP still can reach 30% of all respiratory causes of death. In this work, we propose a machine learning approach to predict mortality risk among elderly inpatients with CAP. The approach uses real world data of elderly people with CAP from a hospital in Brazil, collected from 2018 to 2021. Based on patients data as learning features, our approach is able not only to classify patients at risk of mortality during hospitalization, but also to estimate the probability concerning the prediction. Some classification models have been examined and, among them, the best performance in terms of Area under ROC Curve (AUC) value has been achieved by the Logistic Regression (LR) classifier (AUC=0.81). Accomplished results show that the presented approach outperforms CURB-65 score as baseline in terms of both AUC values and probability of patient death. Besides, our approach is able to output probabilities ranging from 50 to 99% w.r.t. positive classification, i.e., patients that may come to death. A statistical test confirms that the presented approach outperforms the baseline provided by the CURB-65.



Problema: Como prever se pedidos de dívidas (R3D) devem ser aceitos ou negados?

Table 2: Results before and after applying class balancing methods in 10-fold cross-validation scenarios.

Classifier	Unbalanced scenario			After Under Sampling			After SMOTE		
	Mean (Std Dev)	Mean (Std Dev)	Mean (Std Dev)	Mean (Std Dev)	Mean (Std Dev)	Mean (Std Dev)	Mean (Std Dev)	Mean (Std Dev)	Mean (Std Dev)
	ACC	AUC	REC	ACC	AUC	REC	ACC	AUC	REC
Neural Networks	82% (±0,4%)	89% (±0,4%)	87% (±2,5%)	79% ↓ (±0,9%)	88% (±0,3%)	78% ↓ (±4,4%)	81% (±0,7%)	89% (±0,4%)	82% ↓ (±2,3%)
Naive Bayes	58% (±1,4%)	71% (±0,3%)	45% (±3,6%)	55% ↓ (±2,6%)	71% (±0,3%)	38% ↓ (±5,8%)	53% (±1,3%)	71% (±0,3%)	33% ↓ (±2,8%)
Random Forest	88% (±0,3%)	95% (±0,2%)	92% (±0,2%)	87% (±0,4%)	94% (±0,2%)	87% ↓ (±0,5%)	88% (±0,3%)	94% (±0,2%)	91% (±0,3%)
SVM	70% (±0,6%)	71% (±0,4%)	92% (±2,3%)	66% ↓ (±2,6%)	72% (±0,5%)	65% ↓ (±8,5%)	64% ↓ (±1,8%)	72% (±0,4%)	60% ↓ (±6,3%)

On the Evaluation of Classification Methods Applied to Requests for Revision of Registered Debts

Helton Souza Lima¹, Damires Yluska de Souza Fernandes¹, Thiago José Marques Moura¹ and Daniel Sabóia²

¹Instituto Federal da Paraíba, 720 Avenida Primeiro de Maio, João Pessoa, Brasil

²Procuradoria-Geral da Fazenda Nacional, Esplanada dos Ministérios Bloco P, Brasília, Brasil
{helton.souza, damires.souza, thiago.moura}@academico.ifpb.edu.br, daniel.saboia@pgfn.gov.br

Parceria com órgão público

Keywords: Government Data, Tax, Supervised Learning, Imbalanced data.

Abstract: Tax management is a complex problem faced by governments around the world. In Brazil, in order to help solving problems in this area, data analytics has been increasingly used to support and enhance tax management processes. In this light, this work proposes an approach which uses supervised learning in order to classify requests of an administrative service. The requests at hand are named as Requests for Revision of Registered Debt (R3Ds). The service underlying such requests is offered by the Brazil's National Treasury Attorney-General's Office and usually deals with a high volume of registrations. The experimental evaluation accomplished in this work presents some promising results. The obtained classification models present good levels of accuracy, area under ROC curve and recall. Four evaluation scenarios have been experimented, including imbalanced and balanced data. The Random Forest model achieves the best results in all the evaluated scenarios.

Problema: como detectar propensão à depressão por meio de postagens em rede social?

Detecting Signs of Mental Disorders on Social Networks: a Systematic Literature Review

Ayrton Herculano, Glauco Gomes, Damires Souza, Alex Rêgo

Professional Master's in Information Technology (PPGTI)

Federal Institute of Education, Science and Technology of Paraíba (IFPB)


João Pessoa, Brazil

{ayrton.herculano, glauco.gomes}@academico.ifpb.edu.br, {damires, alex}@ifpb.edu.br



Análise de sentimentos

** Dados textuais => modelo preditivo




Terminologias e compreensões



Análise de dados

- ▶ **Analisar dados** é aplicar algum tipo de “**operação/ algoritmo**” nos dados em busca de **informação/conhecimento**



Análise de dados explícita

- ▶ As informações e conhecimento estão **disponíveis explicitamente nos dados**
- ▶ Apenas uma operação (de baixa complexidade) é necessária para produzir o conhecimento que se precisa
 - ▶ Exemplos:
 - ▶ Filtro
 - ▶ Ordenação
 - ▶ Instrução SQL como group by
 - ▶ JOINS

SQL



Análise de dados implícita

- ▶ A informação **não está disponível claramente** no conjunto de dados (normalmente grande)
- ▶ Precisa de uma função/**algoritmo mais sofisticado**
 - ▶ Exemplos:
 - ▶ Função de aprendizado de máquina
 - Para encontrar padrões ocultos nos dados
 - ▶ Função estatística



Análise exploratória

- ▶ Pode usar técnicas tanto quantitativas como visuais


- ▶ **Quantitativas:**

- ▶ Medidas de dispersão e posição como média, mediana, amplitude e desvio padrão

- ▶ **Visuais:**

- ▶ Diagramas, gráficos, histogramas, nuvem de palavras, etc.

	sepal_length	sepal_width	petal_length	petal_width
count	150.000000	150.000000	150.000000	150.000000
mean	5.843333	3.057333	3.758000	1.199333
std	0.828066	0.435866	1.765298	0.762238
min	4.300000	2.000000	1.000000	0.100000
25%	5.100000	2.800000	1.600000	0.300000
50%	5.800000	3.000000	4.350000	1.300000
75%	6.400000	3.300000	5.100000	1.800000
max	7.900000	4.400000	6.900000	2.500000




Business Intelligence

- ▶ BI e seus produtos são exemplos de ferramentas que usam técnicas de análise de dados
- ▶ Algumas trabalham com análise exploratória e explícita; outras também com análise implícita







Fonte: adaptado de CopperTree Analytics, 2019.

Em: www.coppertreeanalytics.com/fundamental-series-on-building-analytics-artificial-intelligence-machine-learning-predictive-analytics-deep-learning-whats-the-difference