

INSTITUTO FEDERAL DE
EDUCAÇÃO, CIÊNCIA E TECNOLOGIA
PARAÍBA
Campus João Pessoa


Fonte e Coleta de Dados

Pesquisa Qualitativa e Quantitativa **Técnicas de Coleta de Dados**

Prof. Alex Cunha
alex@ifpb.edu.br


Atualizado em 16/03/2026

Visão geral do Processo de KDD



Objetivo: Apresentar os principais tipos de fontes de dados e métodos de coleta, destacando aplicações, vantagens, desafios e reflexões.

Natureza da Pesquisa



Por onde começar?

A(s) escolha(a) sustenta(m) a abordagem na condução do estudo

Pesquisa **Qualitativa**



► **Definição**

- Tipo de pesquisa que realiza uma abordagem investigativa (exploratória) voltada para a **explicação de fenômenos sociais, culturais ou comportamentais**”



- Busca explorar significados, percepções, razões, interpretação dos participantes em contextos específicos
- **Não mostra números concretos**, e sim **argumentação lógica, ideias, narrativas e experiências dos participantes** que permeiam a prática na realidade

Pesquisa **Qualitativa**

▶ **Exemplo I (Educação)**

- ▶ **Objetivo:** Investigar como os professores do ensino médio percebem os desafios da inclusão de alunos com deficiência visual e auditiva em sala de aula.
- ▶ **Método:** Entrevistas em profundidade com professores de diferentes escolas.

▶ **Exemplo II (Educação)**

- ▶ **Objetivo:** Compreender o nível de dependência dos alunos de graduação em usar IA Generativa para resolver seus trabalhos acadêmicos
- ▶ **Método:** Grupos focais com estudantes de diferentes cursos



Pesquisa **Qualitativa**

▶ **Métodos de Coleta de Dados**

- ▶ Entrevista em profundidade (conversas individuais guiadas por roteiro aberto)
- ▶ Criação de grupos focais (grupo de discussão sobre um tema, mediada por um facilitador)
- ▶ Observação do participante (pesquisador interage com o ambiente observado)
- ▶ Análise documental (interpretação de texto, imagens, documentos, etc.)

Dados em formato de texto, poucos dados
▶ **(ideias e concepções dos participantes)**

Pesquisa **Quantitativa**



► **Definição**

- “Tipo de pesquisa que realiza uma abordagem sistemática para medir **variáveis, quantificar dados e testar hipóteses (questão de pesquisa) previamente formuladas**
- Utiliza (coleta) dados numéricos estruturados para alcançar um objetivo, **analisados estatisticamente**
- Ideal para estudos que exigem **generalização de resultados** a partir de um grande volume de dados



Pesquisa **Quantitativa**

▶ **Exemplo I (Marketing)**

- ▶ **Objetivo:** Avaliar a **intenção de compra de um novo modelo de transporte elétrico** com base em faixa etária e renda dos consumidores.
- ▶ **Método:** Aplicação de questionário online com 500 participantes e análise estatística dos dados.

▶ **Exemplo II (Educação)**

- ▶ **Objetivo:** Medir **o impacto do uso de tecnologia (tablets)** no desempenho escolar de alunos do ensino médio.
- ▶ **Método:** Comparação estatística de notas entre grupos que usaram ou não a tecnologia, com base em uma amostra representativa

Pesquisa **Quantitativa**


▶ **Métodos de Coleta de Dados**

- ▶ Questionário estruturado (perguntas fechadas, aplicadas presencialmente ou online)
- ▶ Pesquisa de opinião e enquetes (para levantamentos rápidos)
- ▶ Experimentos (manipulação de variáveis para teste de hipóteses)
- ▶ Bases secundárias (uso de bases de dados estatísticas. Ex: IBGE, DataSUS, etc.)

Dados coletados em larga escala



Fontes de Dados



Tipos de fontes de dados referem-se às **várias origens** nos quais os dados são coletados, processados e usados para análises



Tipos de Dados



Information Systems
DATA:
CREATION, MANAGEMENT AND
UTILISATION

Information Systems
Supports open access

Articles & Issues ▾ About ▾ Publish ▾ Order journal ▾

About the journal

Aims and scope Editorial board

Information systems are the software and applications. The journal Information Systems focuses on the implementation of languages, data models and systems for information systems.

➤ Estruturados

➤ Semiestruturados

➤ Não Estruturados

ion	House	Type	Outcome
al	farm	stb	repaid
al	farm	stb	repaid
al	farm	ftb	default
al	apartment	ftb	repaid
nal	apartment	stb	default
al	farm	ftb	default
nal	house	ftb	repaid
nal	farm	ftb	repaid
nal	house	ftb	repaid
al	house	ftb	default
nal	apartment	stb	repaid
	farm	stb	repaid
	apartment	ftb	repaid
	farm	ftb	default
	apartment	ftb	default
	farm	ftb	repaid
	ouse	stb	repaid
	ouse	ftb	repaid
	apartment	ftb	default
	farm	ftb	default
	ouse	stb	repaid
	ouse	ftb	repaid
	ouse	stb	default
	apartment	stb	default
	farm	stb	default

KELLEHER et al., 2015

Subject areas include **data management** issues as presented in the principal international database conferences (e.g., ACM SIGMOD/PODS, VLDB, ICDE and ICDE/EDBT) as well as data-related issues from the fields of data mining/machine learning, information retrieval coordinated

Tipos de Dados

▶ **Estruturado**

- ▶ Dados que obedecem a um esquema rígido, previamente projetado e claro semanticamente (**tipagem definida**)
- ▶ E.g.: dados em formato tabular (SGBD, CSV)

▶ **Semi-Estruturado**

- ▶ Não seguem um esquema rígido, entretanto definem uma organização que facilita seu entendimento (estrutura flexível)
- ▶ E.g.: arquivo JSON, XML **Não são rigidamente tipados**

▶ **Não estruturados**

- ▶ Não possuem uma estrutura pré-definida
- ▶ E.g.: áudio, vídeo, imagem, texto livre



Tipos de Dados

▶ **Origens**

- ▶ **Banco de Dados:** Dados estruturados/semi estruturados armazenados em SGBDs
- ▶ **API:** obtidos a partir de serviços ou aplicações web
- ▶ **Arquivos Simples:** CSVs, planilhas, texto, JSON
- ▶ **Dados de Streaming:** dados continuamente gerados e transmitidos em tempo real de dispositivos IoT, sensores
- ▶ **Serviços de Nuvem:** dados armazenados remotamente em plataformas na nuvem (e.g. AWS)
- ▶ **Entrada Manual:** inseridos por usuários ou operadores
- ▶ **Outra:** web scraping, feeds RSS, mídias sociais



Tipos de Dados

► Origem

Dados Primários

Dados originais, coletados **diretamente da fonte** com um propósito específico em mente

↑ tempo, custo e recurso



Dados Secundários

Dados **coletados por terceiros** e que são reutilizados para uma nova análise

↓ custo e tempo de acesso



Exemplos

- ▶ Dados do IBGE (Censo, PNAD,...)
- ▶ Experimentos laboratoriais
- ▶ Dados públicos de governos ou ONGs
- ▶ Artigos científicos ou relatórios de empresas
- ▶ Questionários aplicados a um público-alvo
- ▶ Entrevistas feitas por um pesquisador
- ▶ Dados de redes sociais coletadas por API
- ▶ Observações de campo



Fonte de Dados

Ao definir as **fontes de dados** para um projeto de ciência de dados, é essencial saber se está lidando com dados **primários** ou **secundários**, pois isso impacta na **forma de coleta, validação, qualidade e uso dos dados**.



Fonte de Dados


► Quadro comparativo

Característica	Dados Primários	Dados Secundários
Origem	Coletado diretamente pelo pesquisador	Coletado por terceiros (pessoas/organizações)
Objetivo	Específicos para um estudo ou problema	Coletado com outro propósito (análises)
Controle sobre a coleta	Total (define-se o método, amostra, etc)	Nenhum (apenas reutiliza o que já existe)
Atualização	Sempre atualizado (é recente)	Podem estar inadequados / desatualizados
Confiabilidade	Alta (se bem coletado e planejado)	Variável (depende da fonte e do método original)
Custo e tempo	Alto	Baixo

Guia de Fontes de Dados



► Fontes públicas e abertas



► Fontes privadas

► Empresas




► Bases acadêmicas e científicas



► Web




Web Scraping



Web Crawling

Coleta de Dados



Processo para obter e reunir dados/informações relevantes a partir de **diversas fontes**, para serem analisadas e transformadas em conhecimento



Métodos de Coleta de Dados

- ▶ **Manual**

- ▶ Entrevistas, questionários, enquetes, observação

- ▶ **Automatizada**

- ▶ Web scrapping, APIs, web crawler, scripts captura de dados

- ▶ **Data Lakes / SGBDS**

- ▶ Dados históricos / múltiplos dados / temporais

- ▶ **Streaming**

- ▶ Processamento contínuo em tempo real

- ▶ **Download em repositórios de dados**

- ▶ Repositórios de datasets, portais de dados abertos



Coleta de Dados

▶ **Por que fazer uma coleta eficiente?**

- ▶ Coleta mal planejada -> consumo de tempo e recursos excessivos
- ▶ Violações de questões éticas na coleta trazem implicações legais
- ▶ Coletar em demasia aumenta a complexidade sem necessariamente melhorar os resultados
- ▶ Transparência sobre como os dados foram coletados aumenta a confiança no processo analítico



Questões Éticas e Legais

- ▶ **A escolha do método de coleta de dados pode trazer implicações legais**

A coleta de dados deve respeitar a LGPD ou outros regulamentos internacionais (GDPR Europa)



Questões Éticas e Legais

- ▶ **Termos de Serviço e Políticas de Privacidade**
 - ▶ Web scraping e Web Crawler não são ilegais...
 - ▶ Muitos sites proíbem explicitamente o **web scraping** em seus Termos de Serviço (ToS)
 - ▶ *Contra coleta automatizada, principalmente quando se tem o propósito de obter lucro com a prática*
 - ▶ A coleta de dados **sem consentimento** é uma violação das leis de privacidade (proteção aos dados de terceiros)
Cuidado ao coletar dados privados diretamente de sites
 - ▶ O **ToS** determina o escopo de utilização da informação contida: **regras e condições de utilização de um “serviço”**



Questões Éticas e Legais

- ▶ **Termos de Serviço e Políticas de Privacidade**
- ▶ **Violar** as regras de privacidade podem resultar em ações legais ou outras penalidades



- **LinkedIn** está sendo processada (Califórnia) por clientes Premium que alegam que a plataforma divulgou suas mensagens privadas a terceiros, sem permissão, **para treinar modelos de IA generativa**
- **Violação:** a plataforma introduziu discretamente uma configuração de privacidade que permitia aos usuários habilitar/desabilitar o compartilhamento de dados pessoais

Questões Éticas e Legais

The Etiquette of Web Scraping and How to Use Web Scraping Legally

June 16, 2022 by **Guest Author**

Guest post by Alexandra Datsenko.

Though web scraping is growing rapidly in popularity and being deployed widely, it's vital to understand the **legal and ethical requirements**.

Although web scraping is perfectly legal, this does not mean that absolutely any content can be collected and actively used. It has to stay within certain limits.

This article presents a look at the etiquette of web scraping and what ethical rules and legal measures exist regarding automatic web data collection.

But first, let's briefly define what web scraping is, and how it is used, for those unfamiliar with the concept.



Image credit: Sora Shimazaki on Pexels

[HTTPS://WEBBIQUITY.COM/MARKETING-TECHNOLOGY/THE-ETIQUETTE-OF-WEB-SCRAPING-AND-HOW-TO-USE-WEB-SCRAPING-LEGALLY/](https://webbiquity.com/marketing-technology/the-etiquette-of-web-scraping-and-how-to-use-web-scraping-legally/)

Precauções contra web scraping

▶ **Robots.txt**

- ▶ Arquivo padrão da indústria usado pelos sites para indicar **quais partes do site os bots (scraper, motores de busca)** não devem acessar
- ▶ É considerada uma prática **ética** respeitar essas diretrizes
- ▶ Arquivo é posicionado na **raiz do site**

`www.dominio.com.br/robots.txt`

- ▶ Composto por regras que determinam um **bot** alvo e o que é ou não permitido
- ▶ *Webscrapping* causa sobrecarga em servidores



Precauções contra web scraping

► Robots.txt

Todos os arquivos podem ser indexados

User-agent: *

Disallow:

Nenhum arquivo pode ser indexado


User-agent: *

Disallow: /


Googlebot não pode indexar qualquer arquivo que inicie por “directory”

User-agent: Googlebot

Disallow: /directory



```
User-agent: *  
  
Disallow: /wp-admin/  
Disallow: /wp-includes/  
Disallow: /assets/  
Disallow: /wp-content/plugins/
```



```
Sitemap: /sitemap.xml.gz  
  
# Define access-restrictions for robots/spiders  
# http://www.robotstxt.org/wc/norobots.html  
  
# By default we allow robots to access all areas of our site  
# already accessible to anonymous users  
  
User-agent: *  
Disallow:  
  
# Add Googlebot-specific syntax extension to exclude forms  
# that are repeated for each piece of content in the site  
# the wildcard is only supported by Googlebot  
# http://www.google.com/support/webmasters/bin/answer.py?answer=40367&ctx=sibling  
  
User-Agent: Googlebot  
Disallow: /*sendto_form$  
Disallow: /*folder_factories$
```

Precauções contra web scraping

- ▶ **Mudança da estrutura do site**

- ▶ Exige a atualização do web scraper regularmente

- ▶ **Bloqueio de IP**

- ▶ Uso de sistemas que identificam bots e bloqueiem o IP caso notem um número de requisições anormais

- ▶ **CAPTCHAs**

- ▶ Teste de desafio cognitivo para impedir o acesso de bots

- ▶ **Autenticação**

- ▶ Restringe o acesso a determinados dados



Recomendações para scraping




- ▶ Verifique o arquivo **robots.txt** e os **Termos de Serviço** antes de iniciar o web scraping
- ▶ Limite a taxa de solicitações do web scraper para evitar sobrecarga do servidor do site
- ▶ Seja ético e respeite as restrições do site
- ▶ Evite coletar dados pessoais sem consentimento
- ▶ Há bibliotecas que facilitam o scraping, pois já possuem mecanismos para evitar bloqueios (e.g. Scrapy)



An open source and collaborative framework
for extracting the data you need from websites.
In a fast, simple, yet extensible way.

Casos de dados mal coletados



Google Flu Trends (2013)

Objetivo: previsão de surtos de gripe com base em buscas feitas pelos usuários no Google

Consequência: superestimou em 140% o número de casos reais de gripe nos EUA. Perdeu a credibilidade e foi descontinuado em 2015

Problema: dependia exclusivamente de dados de busca; muitos termos de busca não estavam relacionados diretamente à gripe

Casos de dados mal coletados



Pew Research Center

RESEARCH TOPICS ▾

PUBLICATIONS

OUR METHODS

SHORT R

[Home](#) > [Research Topics](#) > [Race & Ethnicity](#) > [Racial & Ethnic Groups](#) > ...

SHORT READS | JUNE 8, 2022

SHARE ↗

Key facts about the quality of the 2020 census

BY D'VERA COHN AND JEFFREY S. PASSEL

The [coronavirus pandemic](#) broke out in the United States just as the 2020 census got underway, causing an unprecedented [disruption of operations](#) and [raising questions](#) about the extent of undercounts or overcounts – with implications for political representation and the allocation of [federal](#) and [state](#) resources. [Politics](#), wildfires and extreme weather also may have affected the once-in-a decade count, adding to the doubts among officials, experts and the general public.

The [Census Bureau's own research](#) on data quality has concluded that the national total in the 2020 census was largely accurate, but has estimated miscounts for some states and demographic groups. [The latest research](#), released in May 2022, found that the 2020 census overcounted household populations in eight states while undercounting household populations in six others. The states with overcounts were Delaware, Hawaii, Massachusetts, Minnesota, New York, Ohio, Rhode Island and Utah. Those with undercounts were Arkansas, Florida, Illinois, Mississippi, Tennessee and Texas. By contrast, in the 2010 census, the Census Bureau estimated that no states had overcounts or undercounts.

Censo 2020 EUA

Objetivo: Realizar mapeamento da população americana para definir políticas pública e alocação de verbas

Consequência: cerca de 18,8 milhões ficaram de fora por falha na metodologia de coleta. **Subcontagem de hispânicos**, **supercontagem de população asiática**

Problema: Coleta reduzida por tempo limitado (menos visitas domiciliares); sub-representação de populações vulneráveis

Impacto: distribuição cadeiras no Congresso, repasse de verbas, planejamento de serviços sociais

Fonte e Coleta de Dados

► ATIVIDADE



**Quais fontes de dados seriam úteis
para um projeto de previsão de
ingresso no mestrado do PPGTI?**



-
- ▶ Qual a diferença entre pesquisa qualitativa e quantitativa?
<https://www.questionpro.com/blog/pt-br/diferenca-pesquisa-qualitativa-e-quantitativa/>
 - ▶ O Web Scraping é legal? Abrangendo todos os aspectos.
<https://medium.com/@datajournal/is-web-scraping-legal-0df27c2e2ec6>
 - ▶ Is web scraping illegal?
<https://datadome.co/guides/scraping/is-it-legal/#:~:text=Web%20scraping%20activities%20that%20may,or%20sensitive%20information%20without%20consent.>
-

