


INSTITUTO FEDERAL DE
EDUCAÇÃO, CIÊNCIA E TECNOLOGIA
PARAÍBA
Campus João Pessoa

Atividades de pré-processamento

Pré-processamento
Tratamento de Dados

Prof. Alex Cunha
alex@ifpb.edu.br

Visão geral do Processo de KDD



Objetivo:

Realizar o tratamento, adequação e organização dos dados “brutos” para um formato adequado à realização de **análises de dados** ou criação de modelos de **aprendizado de máquina**.

Importância

- ▶ Conferir a **qualidade dos dados**
 - ▶ **Precisão:** os dados selecionados estão corretos?
 - ▶ **Compleitude:** os valores de todas as colunas estão disponíveis? São os esperados? Há valores ausentes?
 - ▶ **Consistência:** os dados são uniformes? São valores válidos? Estão livres de contradições?
 - ▶ **Pontualidade:** os dados estão limitados a um período específico? Podem ser afetados ao passar do tempo?
 - ▶ **Credibilidade:** os dados demonstram que são confiáveis?
 - ▶ **Interpretabilidade:** o significado dos dados pode ser compreendido? São claros?



Recursos Disponíveis



Atividades de análise inicial e preparação de dados

- Integração 
- Análise dos dados
- Limpeza
- Padronizações
- Transformações
- Enriquecimento
- Redução da dimensionalidade

Qual a análise alvo?



Por quê?

co_lograd	nome_log	co_geo_c	co_geo_c	nome_ref	nu_cep	tp_zona_r	co_pais_r	redt_investiga	co_cbo_o	febre	mialgia	cefaleia	exantema	vomito	nausea	dor_costa	conjutivite	artrite
	RUA BELEM DE SAO FRANCISCO					1	1	03/10/2016		1	1	1	2	2	1	2	2	2
LOS	ESTRADA DO SITIO DOS PINTOS						1	04/06/2016		2	2	2	2	2	2	2	2	2
IA	RUA CAMPO DA UNIAO					1	1	02/01/2016										
	RUA ADRIANO VIEIRA					1	1	02/11/2016		1	2	1	1	2	2	2	2	2
	RUA SIMPERE					9	1	01/08/2016										
L	RUA NORMANDIA					1	1	01/11/2016										
	RUA 2 DE SETEMBRO		PROX. A P	51345140		1	1	09/09/2016	354110	1	2	1	2	1	2	2	2	2
A	RUA VELHA				50060210		1	02/04/2016										
IA	RUA TEREZA CARNEIRO						1	01/08/2016										
A	AV BEBERIBE					1	1	01/11/2016										
IA	RUA CAMPO DA UNIAO					1	1	01/06/2016										
A	NOSSA SENHORA DA CONCEIÇÃO				52111470	1	1	03/03/2016										



<http://dados.recife.pe.gov.br/dataset/casos-de-dengue-zika-e-chikungunya>

- Tudo começa pelos dados...

Outro exemplo

Nome	Idade	Nível educacional	Estado civil	Gênero	Cartão de crédito	Renda mensal (\$)
Roberto Felix	42	Especialização	Divorciado	M	Sim	5.000
Joana Pereira	10	Doutorado	Viúva	F	Sim	6.500
?	?	?	?	?	?	?
Isabela Assis	33	Graduação	Casada	F	?	3.900
Marco Araújo	29	Graduação	89 Kg	M	Não	3.100

Fonte: de Castro e Ferrari, 2016

#exemploradical

“Dados brutos” são aqueles que ainda não foram processados para uso



É preciso estudar, analisar e entender os dados brutos

E evitar o “garbage in garbage out”




=> A qualidade da saída depende da qualidade da entrada



- 
- 
- i. Entender os dados
 - ii. Realizar análises iniciais
 - iii. Tratar e preparar os dados...

Dataframes: A New Data Model and API



The diagram illustrates the structure of a Dataframe. It consists of a large grey rectangle labeled 'Array' in the center. To its left is a vertical pink rectangle labeled 'Row Labels'. Above the 'Array' rectangle are two horizontal rectangles: a light green one labeled 'Column Domains' and a light red one labeled 'Column Labels'.

Dataframes: Mixed type-array, w/ row and column labels

`df.describe(...)`
`df.rename(...)`
`pd.concat(...)``df.drop(...)`
`df.groupby(...)`
`pd.join(...)`
`df.pivot(...)``pd.merge(...)`

600+ functions to clean, reshape, explore, and summarize data spanning rel., linear, & spreadsheet algebra

Um **tour** com Pandas

► O dataset **tmdb5000.csv** (the movie database TMDb)

<https://www.kaggle.com/datasets/tmdb/tmdb-movie-metadata?resource=download>

1. Carga dos Dados

✓ 1.1 Direto do drive

► Metadados descritivos de FILMES?

```
from google.colab import drive
import pandas as pd

drive.mount('/content/drive', force_remount=True)

# Caminho completo para o arquivo
file_path = '/content/drive/My Drive/datasets/tmdb_5000_movies.csv'


# Carregando o dataset
df = pd.read_csv(file_path)

# Exibindo as primeiras linhas
df.head()
```

Mounted at /content/drive

	budget	genres	homepage	id	keywords	original_language	original_title	overview
0	237000000	[{"id": 28, "name": "Action"}, {"id": 12, "name": "Adventure"}]	http://www.avatarmovie.com/	19995	[{"id": 1463, "name": "culture clash"}, {"id": 1464, "name": "culture clash"}]	en	Avatar	In the 22nd century, a paraplegic Marine is dispatched on a mission...

Metadados estruturais



TMDB 5000 Movie Dataset

► Atributos ou features de FILMES

- **Budget:** orçamento do filme
- **Homepage:** página do filme na internet
- **Keywords:** lista de palavras-chave associadas ao filme
- **Original language:** idioma original
- **Overview:** descrição geral
- **Popularity:** nível de popularidade
- **Release date:** data de lançamento
- **Revenue:** faturamento
- **Runtime:** duração
- **Vote count** e **vote average:** número de votos e a média das notas

Conhecendo o dataset

```
df_filmes.info()
```

```
<class 'pandas.core.frame.DataFrame'>  
RangeIndex: 4803 entries, 0 to 4802  
Data columns (total 20 columns):  
#   Column                Non-Null Count  Dtype    
---  ---                  
0   budget                4803 non-null   int64     
1   genres                4803 non-null   object    
2   homepage              1712 non-null   object    
3   id                    4803 non-null   int64     
4   keywords              4803 non-null   object    
5   original_language     4803 non-null   object    
6   original_title        4803 non-null   object    
7   overview              4800 non-null   object    
8   popularity            4803 non-null   float64   
9   production_companies  4803 non-null   object    
10  production_countries  4803 non-null   object    
11  release_date          4802 non-null   object    
12  revenue               4803 non-null   int64     
13  runtime              4801 non-null   float64   
14  spoken_languages      4803 non-null   object    
15  status               4803 non-null   object    
16  tagline               3959 non-null   object    
17  title                4803 non-null   object    
18  vote_average          4803 non-null   float64   
19  vote_count            4803 non-null   int64     
dtypes: float64(3), int64(4), object(13)  
memory usage: 750.6+ KB
```

```
# Número de linhas e atributos  
df_filmes.shape
```

```
(4803, 20)
```

Limpeza

- ▶ Busca assegurar a **qualidade dos dados**
 - ▶ **Completude + veracidade + integridade/consistência**
- ▶ Pode ser necessária a imputação de **valores ausentes**, remoção de **ruídos** e/ou correção de **inconsistências**



Valores ausentes

- ▶ Um **valor ausente** é aquele que não está presente em uma coluna de dados mas existente no contexto em que a obtenção do valor do atributo foi realizada.
- ▶ Pode estar representado por **valor negativo**, nulo (**NaN**, **NULL**) ou **branco/traço** ou uma mesma constante



Valores ausentes

- ▶ O **dado faltante** é uma informação real (existe/existiu) pertinente que **deveria ter sido registrada**, mas não foi por alguma razão

Data da última vacina = ?

(Não significa que um paciente nunca foi vacinado; a informação **existe no contexto**, mas não foi registrada)

- ▶ Decorrente de **falha** ou **incompletude** no processo de coleta



Valores inaplicáveis

- ▶ Um **valor inaplicável** é um tipo específico de valor ausente **inexistente no contexto** em que sua obtenção foi realizada (não é uma falha de coleta)
- ▶ Sua ausência é **intencional** ou **lógica**
- ▶ E.g.,

Estado Civil = Solteiro

Nome do Cônjuge = null

Sexo = Masculino

Número de Partos = null



Ruídos

- ▶ Um **valor impreciso ou incorreto** que compromete a qualidade dos dados e introduz distorção na análise

- ▶ **Causas:**

- ▶ Erro de digitação

```
data_de_nascimento = '05-o4-2025'
```

- ▶ Dados inconsistentes

```
idade = 150 # ou -5
```

- ▶ Valores duplicados ou redundantes

- ▶ Um mesmo aluno cadastrado várias vezes com pequenas variações no nome

- ▶ Presença de outlier

```
Cargo = 'analista junior'  
Salario = 300000.00
```

- ▶ Leitura errada de dispositivos

```
Temperatura = -100 # 0..50
```



Ruídos

▶ Tratamento

- ▶ Correção ou exclusão de registros inválidos
- ▶ Uso de técnicas de imputação de valores (ausentes)
- ▶ Normalização ou Padronização 
- ▶ Tratamento de outliers 



Tratamento para valores ausentes

▶ Eliminação de atributos:

- ▶ Abordagem mais simples, pois as soluções são construídas apenas com atributos que possuem informação

▶ Substituição por um único valor:

- ▶ A variável é **categórica** e pode ser tratada como uma nova categoria:

'desconhecido' 'sem resposta'

- ▶ **Valores ausentes** podem ter um significado específico

```
id_cliente = 13567
```

```
data_primeira_compra = 2024-10-21
```

```
num_reclamacoes_por_mes = ?
```

Ausência do valor sugere que o cliente nunca fez reclamação.

Então, pode ter sentido substituir por 0 (zero)

Tratamento para valores ausentes

► Valor médio do atributo

- Indicado quando os dados são **normalmente distribuídos**

DataFrame original:

Número de Veiculos Vendidos

	janeiro	fevereiro	março
0	1.0	NaN	10.0
1	2.0	6.0	11.0
2	NaN	7.0	12.0
3	4.0	8.0	NaN
4	5.0	NaN	14.0

Média da coluna A: 3.00

Média da coluna B: 7.00


Média da coluna C: 11.75

Número de Veiculos Vendidos

	janeiro	fevereiro	março
0	1.0	7.0	10.00
1	2.0	6.0	11.00
2	3.0	7.0	12.00
3	4.0	8.0	11.75
4	5.0	7.0	14.00

Distribuição

gaussiana: a maioria dos dados se concentra em torno da média (simétrica em relação à média)



Tratamento para valores ausentes

► Mediana:

- A distribuição dos dados é **assimétrica** (não normal)
- Presença de outliers

Antes do tratamento:

	idade
0	25.0
1	30.0
2	NaN
3	22.0
4	28.0
5	NaN
6	35.0

Mediana = 28.0

Depois do tratamento:

	idade
0	25.0
1	30.0
2	28.0
3	22.0
4	28.0
5	28.0
6	35.0

Tratamento para valores ausentes

► Moda (atributos categóricos):

► Conceito de valor mais frequente

DataFrame original:

	ID Cliente	Cor Favorita
0	1	Azul
1	2	Verde
2	3	Azul
3	4	NaN
4	5	Vermelho

DataFrame após preencher os

	ID Cliente	Cor Favorita
0	1	Azul
1	2	Verde
2	3	Azul
3	4	Azul
4	5	Vermelho

► Interpolação

- É razoável supor que o valor mais recente (antes ou depois) é válido, até que um novo valor apareça 🕒

► Ignorar linhas ausentes

- Quantidade de dados é pequena e a exclusão não faz diferença



Ausentes: alguns métodos



- ▶ O método **isnull()** indica se os valores são nulos; o **notnull()** retorna o contrário
- ▶ O método **info()** é uma das formas também de se verificar a presença de valores ausentes
- ▶ Método **dropna()** pode ser usado para retirar linhas/colunas que tenham valores faltantes
- ▶ Método **fillna()** pode ser usado para preencher com valores (e.g. média, mediana,...)



Verificação de valores ausentes: **isnull()**

Exemplo “Filmes”

```
# conhecendo o dataset e sua estrutura de metadados  
filmes.info()
```

```
<class 'pandas.core.frame.DataFrame'>  
RangeIndex: 4803 entries, 0 to 4802  
Data columns (total 20 columns):  
#   Column                Non-Null Count  Dtype    
---  -  
0   budget                 4803 non-null  int64    
1   genres                 4803 non-null  object   
2   homepage               1712 non-null  object   
3   id                     4803 non-null  int64    
4   keywords               4803 non-null  object   
5   original_language      4803 non-null  object   
6   original_title         4803 non-null  object   
7   overview               4800 non-null  object   
8   popularity             4803 non-null  float64   
9   production_companies   4803 non-null  object   
10  production_countries    4803 non-null  object   
11  release_date            4802 non-null  object   
12  revenue                 4803 non-null  int64    
13  runtime                 4801 non-null  float64   
14  spoken_languages       4803 non-null  object   
15  status                  4803 non-null  object   
16  tagline                 3959 non-null  object   
17  title                   4803 non-null  object   
18  vote_average            4803 non-null  float64   
19  vote_count              4803 non-null  int64    
dtypes: float64(3), int64(4), object(13)  
memory usage: 750.6+ KB
```

```
filmes.isnull().sum()
```

```
budget                0  
genres                0  
homepage              3091  
id                    0  
keywords              0  
original_language     0  
original_title        0  
overview              3  
popularity            0  
production_companies  0  
production_countries  0  
release_date          1  
revenue               0  
runtime               2  
spoken_languages      0  
status                0  
tagline               844  
title                 0  
vote_average          0  
vote_count            0  
dtype: int64
```


Nos dados – filmes.homepage

```
df_filmes[df_filmes['runtime'].isnull()]
```

	budget	genres	homepage	id	keywords	original_language	original_title	overview	popularity
2656	15000000	[{"id": 18, "name": "Drama"}]	NaN	370980	[{"id": 717, "name": "pope"}, {"id": 5565, "na...	it	Chiamatemi Francesco - Il Papa della gente	NaN	0.738646
4140	2	[{"id": 99, "name": "Documentary"}]	NaN	459488	[{"id": 6027, "name": "music"}, {"id": 225822, ...	en	To Be Frank, Sinatra at 100	NaN	0.050625

NaN = Not a Number

Ausentes: alguns métodos



- Métodos de interpolação básicos: **ffill**, **bfill** e **mean()**

Original:

	data	temperatura
0	2024-01-01	22.1
1	2024-01-02	NaN
2	2024-01-03	NaN
3	2024-01-04	23.0
4	2024-01-05	NaN
5	2024-01-06	24.5
6	2024-01-07	NaN

Forward Fill (valor anterior):

	data	temperatura
0	2024-01-01	22.1
1	2024-01-02	22.1
2	2024-01-03	22.1
3	2024-01-04	23.0
4	2024-01-05	23.0
5	2024-01-06	24.5
6	2024-01-07	24.5

Backward Fill (valor posterior):

	data	temperatura
0	2024-01-01	22.1
1	2024-01-02	23.0
2	2024-01-03	23.0
3	2024-01-04	23.0
4	2024-01-05	24.5
5	2024-01-06	24.5
6	2024-01-07	NaN

Exemplos com dropna()

```
#remove as linhas que tenham valor nulo  
filmes1 = filmes.dropna()
```

```
#Remove as colunas com valor nulo  
filmes2 = filmes.dropna(axis=1)
```

```
# remove com base em um subconjunto de colunas  
filmes3 = filmes.dropna(subset=['homepage', 'tagline'])
```



Exemplo com fillna()

Antes do tratamento:

	nome	profissao
0	Ana	Engenheira
1	Bruno	None
2	Carlos	Médico
3	Diana	None

Depois do tratamento:

	nome	profissao
0	Ana	Engenheira
1	Bruno	Desconhecido
2	Carlos	Médico
3	Diana	Desconhecido

```
#substituindo o valor ausente em profissao por 'Desconhecido'  
df['profissao'] = df['profissao'].fillna('Desconhecido')
```



Exemplos com fillna()

```
[1] import pandas as pd
```

```
[2] data = [0.5, None, None, 0.52, 0.64, None, None, 0.59, 0.6, None, 0.8]  
s = pd.Series(data)
```

```
s  
0    0.50  
1     NaN  
2     NaN  
3    0.52  
4    0.64  
5     NaN  
6     NaN  
7    0.59  
8    0.60  
9     NaN  
10   0.80  
dtype: float64
```

```
#preenchendo os nulos com 0  
s1 = s.fillna(0)
```

```
#preenchendo os valores nulos com ffill  
s2 = s.ffill()
```

```
#preenchendo os campos nulos com a média  
s2 = s.fillna(s.mean())
```

Classificação dos Atributos

► **Categórico, qualitativo ou simbólico**

- *Descreve uma propriedade (não numérica) pertencente à uma categoria*

a) **Ordinais (com ordem)**

Possui uma hierarquia de **ordem natural**, mas a diferença de valores **pode não ser mensurável**

```
pizza = {'pequena', 'média', 'grande'}
```

```
escolaridade = {'fundamental', 'medio', 'superior'}
```

b) **Nominais: (sem ordem)**

Não possui uma relação de ordem natural

```
pizza = {'frango', 'quatro queijos', 'tomate seco'}
```

```
cor = {'azul', 'amarelo', 'vermelho', 'verde'}
```

Variáveis ou atributos

► Variável categórica

filmes.**original_language**.unique()

Exemplo “Filmes”

```
[20] # variável categórica do atributo "original_language" sem repetição  
df_filmes['original_language'].unique()
```

```
array(['en', 'ja', 'fr', 'zh', 'es', 'de', 'hi', 'ru', 'ko', 'te', 'cn',  
      'it', 'nl', 'ta', 'sv', 'th', 'da', 'xx', 'hu', 'cs', 'pt', 'is',  
      'tr', 'nb', 'af', 'pl', 'he', 'ar', 'vi', 'ky', 'id', 'ro', 'fa',  
      'no', 'sl', 'ps', 'el'], dtype=object)
```

```
len(df_filmes['original_language'].unique())
```

```
37
```

```
df_filmes['original_language'].value_counts()
```

```
count  
original_language  
en      4505  
fr       70  
es       32
```

Classificação dos Atributos

- ▶ **Numérico ou quantitativo**

*Representam valores numéricos reais e **permitem operações matemáticas***

- ▶ **Contínuo** (incontáveis)

Pode assumir um número infinito de valores, incluindo frações e casas decimais)

- ▶ E.g., medidas como peso (65,8 kg) , tamanho (1,85m)

- ▶ **Discreto** (contável)

Assume valores inteiros finitos dentro de um intervalo

- ▶ E.g., quantidade de filhos, idade, números de acessos a um site



Variáveis ou atributos

► Variável quantitativa contínua

filmes.budget

filmes['budget']



```
# variável quantitativa contínua  
df_filmes['budget']
```



	budget
0	237000000
1	300000000
2	245000000
3	250000000
4	260000000
...	...
4798	220000
4799	9000
4800	0
4801	0
4802	0

4803 rows × 1 columns

dtype: int64

Variáveis ou atributos

- ▶ Variável quantitativa discreta intervalar (vote)

filmes.vote_count

```
df_filmes.vote_count.describe()
```



	vote_count
count	4803.000000
mean	690.217989
std	1234.585891
min	0.000000
25%	54.000000
50%	235.000000
75%	737.000000
max	13752.000000

dtype: float64



```
# variável quantitativa intervalar: vote_count  
df_filmes['vote_count']
```



	vote_count
0	11800
1	4500
2	4466
3	9106
4	2124
...	...
4798	238
4799	5
4800	6
4801	7
4802	16

4803 rows × 1 columns

dtype: int64

Classificação dos Atributos

► **Binário**

Caso especial dos categóricos nominais, pois só possuem dois valores possíveis

► Exemplos:

resposta_do_usuario: sim/não

diagnóstico_da_doença = positivo/negativo

roteador = ligado/desligado



Classificação dos Atributos

► Temporais

*Relacionados a “tempo” e podem ser tratados como **numérico** ou **categórico**, dependendo do contexto*

► Exemplos:

data_admissão: '2024-07-03'

anos_experiência_docência = 15

hora_do_dia = '14:30'



Classificação dos Atributos

- ▶ **Espaciais (geográficos)**

Relacionados a posição geográfica

- ▶ Exemplos:

latitude_SP: '-23.550520'

longitude_SP: '-46.633308'

região_do_brasil = 'nordeste'

CEP = '58050-000'



Outros tratamentos

- ▶ Diferenças em unidades, escalas e conversões
 - ▶ Distância: 1600 m => 1,6Km
- ▶ Caracteres especiais ou símbolos específicos
 - ▶ Muito obrigado pela atenção e boa tarde ;)
- ▶ Capitalização e formatações gerais
 - ▶ Sexo_biológico/Gender:
Feminino | F | feminino | 0 | FEM | FEMALE



Exemplo

cargo	sexo_biologico	idade
Marketing Associate	Female	22
Marketing Associate	Female	26
Graphic Designer	Male	30
Marketing Associate	Female	41
Warehouse Associate	Female	19
IT	Female	22
Sales Associate	Male	20
Marketing Associate	Female	30
Marketing Associate	Female	20
Marketing Associate	Female	34

#dicionário para substituir os valores

```
sexo = {'Male':'M', 'Female':'F'}
```

#mapeando os valores

```
empregos1 = empregos['sexo_biologico'].map(sexo)
```

```
empregos['sexo_biologico'] = empregos1
```

```
empregos['sexo_biologico']
```

sexo_biologico	
465	F
348	F
824	F
949	M
590	F
...	...
357	F
799	M
609	M
353	M
927	M